SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Domagoj Rojnić

Diplomski studij

ZADAVANJE NAREDBI WINDOWS SUSTAVU GLASOM

Raspoznavanje uzoraka i strojno učenje

Osijek, 2021.

SADRŽAJ

1. Uvod

Prepoznavanje govora (engl. speech recognition), poznato kao i automatsko prepoznavanje govora (engl. automatic speech recognition, ASR), predstavlja sposobnost koja omogućava programu računalnog sustava obradu ljudskog govora i pretvorbu govora u tekstualni zapis. Iako se često miješa s prepoznavanjem glasa (engl. voice recognition), prepoznavanje govora fokusira se na pretvorbu govora iz verbalnog u tekstualni oblik, dok se kod prepoznavanja glasa želi identificirati glas pojedinog korisnika.

1.1. Opis projektnog zadatka

Cilj ovog projektnog zadatka bio je implementirati sustav koji omogućuje izvođenje Windows naredbi glasom. Potrebno je obraditi i transformirati glasovni oblik u tekstualni zapis rečenih naredbi. Odabrano je 8 naredbi koje se izvršavaju pomoću različitih biblioteka unutar Python skripte.

2. Prepoznavanje govora

Računalna snaga i umjetna inteligencija uvelike stoje iza napretka u području obrade i prepoznavanja govora. Uz ogromne količine govornih podataka i kombinacijom s brzom obradom podataka, prepoznavanje govora dostiglo je točku gdje su njegove mogućnosti približno jednake ljudskim. Slikom 2.1. u nastavku dan je graf koji prikazuje napredak postotka točnosti prepoznavanja govora Google-ovog sustava za prepoznavanje ostvarenog metodama strojnog učenja.

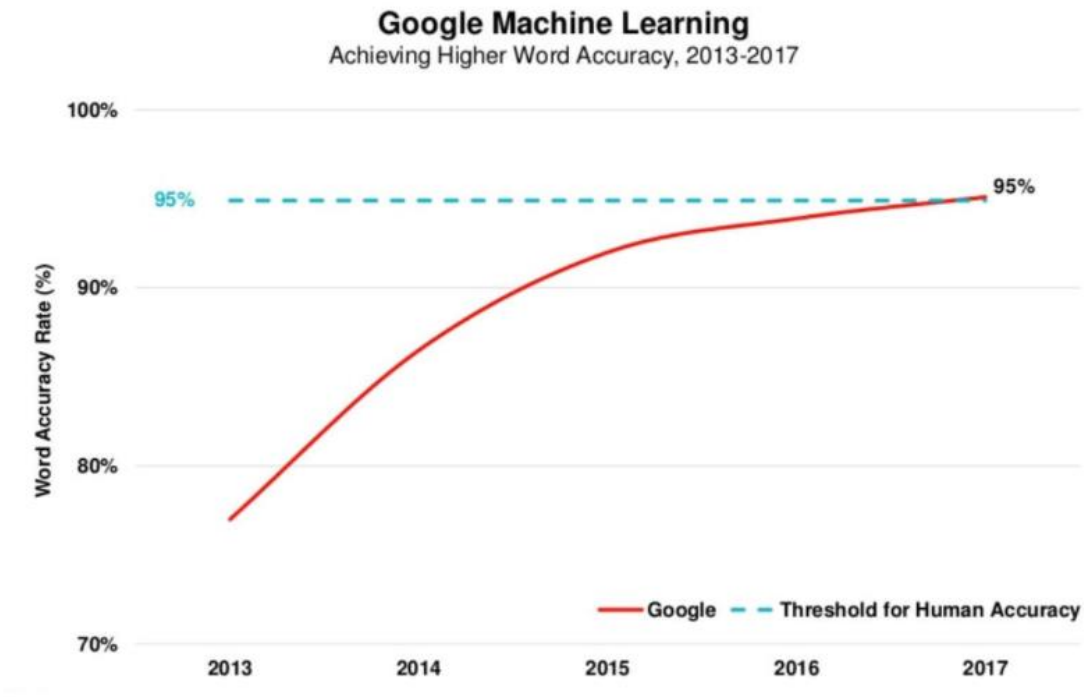

Slika 2.1. Graf postotka točnosti Google-ovog sustava prepoznavanja govora

Iako je u posljednje vrijeme bilo puno koraka prema naprijed, prepoznavanje govora datira jos od ranih 1950-ih. Nadalje su kratko navedeni ključni događaji koji su oblikovali ovu tehnologiju u posljednjih 70 godina.

2.1. Povijest

Prvi sustavi prepoznavanja govora bili su usmjereni na brojeve, a ne riječi. 1952. Bell Laboratories dizajnirali su „Audrey“ sustav koji je mogao prepoznati pojedine izgovorene

znamenke. Deset godina kasnije, IBM je predstavio sustav „Shoebox“ koji je razumio i odgovarao na 16 riječi.

Diljem svijeta zemlje su razvijale vlastito sklopovlje i programe koje je obrađivalo i prepoznavalo govor. Krajem 60-ih, omogućeno je prepoznavanje riječi koje sadrže do 4 samoglasnika i čak do 9 suglasnika.

Najveći napredak tijekom 1970-ih ostvaren je zahvaljujući Ministarstvu obrane SAD-a i DARPA-i. Oni su proveli istraživanje razumijevanja govora kojim su stvorili „Harpy“ sustav kojime je omogućeno prepoznavanje do 1000 riječi što je slično vokabularu trogodišnjeg djeteta.

80-ih godina sustavi počinju raspoznavati i po par tisuća riječi, a najveći proboj u prepoznavanju govora dolazi zahvaljujući statističkoj metodi skrivenih Markovljevih modela (engl. Hidden Markov Models, HMM). Umjesto čistog korištenja riječi i traženja obrazaca, HMM izračunava vjerojatnost da su nepoznati zvukovi zapravo riječi.

Sve do 2001. godine, sustavi raspoznavanja govora ostvaruju oko 80% točnosti. Veliku prekretnicu predstavlja Google-ov *Voice Search*, aplikacija koja je dana milijunima ljudi na korištenje čime je sustav s vremenom uključivao raspoznavanje 230 milijardi riječi.

2010-ih Apple lansira Siri, Amazon Alexu, a Google izbacuje Google Home, gdje potrošačima postaje sve ugodnije razgovarati sa strojevima.

2.2. Današnjica

Danas se neke od najvećih tehnoloških tvrtki natječu u ostvarivanju što veće točnosti prilikom prepoznavanja govora. 2016. godine IBM je postigao stopu pogreške od 6,9%. 2017. godine Microsoft postiže 5,9% nakon čega je ubrzo IBM nadmašio njihovu stopu s 5,5%. Međutim, trenutnu pobjedu odnosi Google koji je uspio ostvariti stopu pogreške od 4,9%.

Korištenje sustava raspoznavanja govora danas nema granica, pri čemu se uvelike pomaže tvrtkama i klijentima u uštedi vremena. U automobilskoj industriji sustavi prepoznavanja poboljšavaju vozačevu sigurnost omogućavanjem izvođenja naredbi aktivacijom govora poput navigacije. Svakodnevno se koriste digitalni asistenti koji su ugrađeni u mobilne

uređaje, time pomažući korsnicima s raznim zahtjevima. U zdravstvu omogućuju zapisivanje i vođenje dnevnika bolesti i dijagnoza pojedinih pacijenata.

2.3. Glavne značajke sustava

Mnogi programi su dostupni za prepoznavanje govora, ali naprednija rješenja koriste postupke strojnog učenja i umjetne inteligencije. Oni integriraju gramatiku, sintaksu, strukturu i sastav zvučnih signala kako bi razumjeli i obradili ljudski govor. Različite vrste sustava omogućuju različitim korisnicima da prilagode tehnologiju svojim specifičnim zahtjevima, od jezika i nijansi govora do prepoznavanja robnih marki. Ipak, svi ovi sustavi imaju zajedničke značajke koje je potrebno implementirati na neki od mogućih načina kako bi se izgradio kvalitetan i robustan sustav raspoznavanja.

Pridruživanje težina određenim riječima koje se često govore izvan pojmova koji su već u osnovnom riječniku uvelike povećavaju preciznost sustava. Označavanje govornika također poboljšava sustave jer time se može kao izlaz dobiti slijed govora koji označava pojedine govornike u razgovoru s više sudionika, čime se određuje doprinos svakog govornika. Jedna od najvažnijih značajki je mogućnost prilgodbe okolišu i akustičnom okruženju, čime se mogu identificirati stalno pristuni zvukovi koji bi mogli ometati sustav raspoznavanja. Njih je potrebno prepoznati i kao takve ukloniti iz govora koji se prepoznaje kako bi se dobio što čišći i precizniji odgovor. Naposlijetku, potrebni su razni filteri koji će filtrirati određene riječi, fraze i sanirati sam govor.

2.4. Algoritmi u sustavima raspoznavanja govora

Sustavi raspoznavanja govora implementiraju različite algoritme i tehnike kojima se govor raspoznaje i transformira u tekst. U nastavku su kratko opisani najznačajniji algoritmi koji se danas koriste.

Obrada prirodnog govora (engl. Natural language processing, NLP) kao područje umjetne inteligencije zasniva se na poboljšanju interakcije čovjeka i računala putem pretvorbe govora u tekst različitim tehnikama obrade i transformacije riječi i rečenica.

Skriveni markovljevi modeli (HMM) predviđaju vjerojatnost zvukova da su riječi te se koristi kao model unutar prepoznavanja govora dodjeljujući oznake svakoj jedinici, odnosno

riječima ili slogovima u rečenicama. Ove oznake mapiraju navedeni ulaz i omogućavaju sustavu da obradi najprikladniji slijed govora temeljem tih oznaka.

N-grami (engl. N-grams) znakova predstavlja najjednostavniji tip jezičnog modela koji rečenicama ili frazama dodjeljuje vjerojatnost. N-gram je zapravo slijed od n riječi u rečenici. Gramatika i vjerojatnost određenih sljedova riječi koriste se za poboljšanje prepoznavanja i točnosti.

Neuronske mreže (engl. Neural networks, NN) predstavljaju algoritam dubinskog učenja pomoću kojeg se pronalaze skrivene povezanosti među riječima i rečenicama čime se znatno povećava preciznost sustava prepoznavanja.

Diarizacija govornika (engl. Speaker diarisation) identificira i segmentira govor prema identitetu govornika pri čemu znatno pomaže sustavu u razlikovanju pojedinaca u razgovoru.

3. Programsko rješenje

Prethodno naveden cilj projekta također se može prikazati dijagramom na slici 3.1. Korisnik kao ulaz daje glasovnu naredbu putem mikrofona, koji može biti ili ugrađen u Windows računalo ili eksterno povezan, nakon čega se glasovna naredba pretvara u tekst koristeći metode SpeechRecognition biblioteke. Konvertirani tekst je tada mapiran pojedinim GUI zadatcima, poput upravljanja mišem ili tipkovnicom, prilikom čega su aktivnosti izvedene pomoću PyAutoGUI biblioteke.

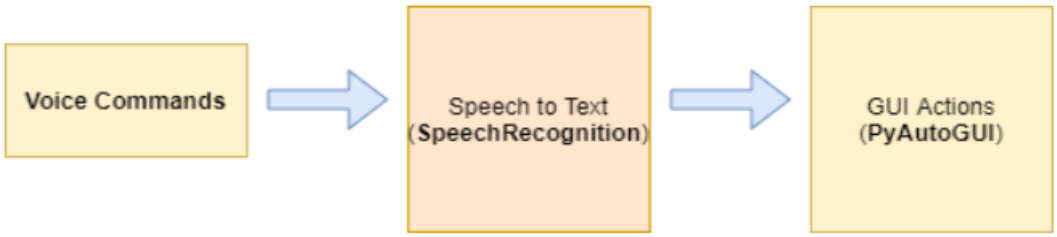

Slika 3.1. Dijagram zadatka

3.1. SpeechRecognition biblioteka

SpeechRecognition Python biblioteka nudi veliki niz mogućnosti u različitim aspektima kućnih automatskih sustava, učenja jezika pa sve do digitalnih asistenata. Korištenjem ove biblioteke omogućena je pretvorba govora u tekst. Podupire nekolicinu API-ja, *online* te čak i *offline*. Instalacija biblioteke u projekt izvodi se kako je prikazano na slici 3.1.1. prilikom čega se također instalira *pyaudio* biblioteka kako bi se moglo pristupiti mikrofonu.

```
pip install SpeechRecognition
pip install pyaudio
```

Slika 3.1.1. Instaliranje biblioteka

Sljedećom slikom, vidljiv je kod kojim se uvodi biblioteka te inicijalizira *recognizer* objekt koji sluša glas putem mikrofona i pretvara ga u tekst. Pozivom funkcije *recognizer.adjust_for_ambient_noise()* je opcionalno, ali vrlo korisno. Ova funkcija sluša

ulazni zvuk bez govora onoliko sekundi koliko je predano u parametru *duration* i mijenja vrijednost *energy_threshold* ovisno o količini buke koja je prisutna u sobi. Ovo radi kako bi prilikom raspoznavanja govora mogao odstraniti buku okoliša i što točnije klasificirati danu naredbu. Njome se također mjeri „osjetljivost“ *recognizer* objekta. Dobivena vrijednost varira u rasponu od 50 do 4000 gdje veće vrijednosti predstavljaju više buke i manju osjetljivost na ulazni signal govora.

Funkcijom *recognizer.listen()* se sluša naredba putem mikrofona koja se sprema u varijablu audio. Zatim se varijabla prosljeđuje *recognizer* objektu koji pretvara zvuk u tekst.

```
1  import speech_recognition
2
3  recognizer = speech_recognition.Recognizer()
4
5  with speech_recognition.Microphone() as src:
6
7      audio = recognizer.adjust_for_ambient_noise(src, duration=0.5)
8      while True:
9          try:
10             print("\nPlease speak:")
11             audio = recognizer.listen(src)
12             speech_to_txt = recognizer.recognize_google(audio).lower()
13         except Exception as ex:
14             print("Sorry. Could not understand.\n\n")
15             continue
```

Slika 3.1.2. Početni dio koda

3.2. PyAutoGUI biblioteka

Python nudi biblioteku PyAutoGUI za GUI automatizaciju koja simulira klikanje miša i pritiskanje tipki na tipkovnici kao da ih i sam čovjek obavlja. Na primjer, moguće je sve od simuliranja kretnje miša, povećavanja i smanjivanja otvorenih prozora pa sve do mijenjanja razine zvuka i otvaranje instaliranih aplikacija. Instaliranje je prikazano na slici 3.2.1. te se izvodi na isti način kao i kod SpeechRecognition biblioteke.

```
pip install PyAutoGUI
```

Slika 3.2.1. Instaliranje PyAutoGUI biblioteke

Kretnje miša simuliraju se na način da se dohvaćaju x i y koordinate na zaslonu. Zaslon se može zamisliti kao 2D prostor čije se (0, 0) koordinate nalaze u gornjem lijevom kutu. Kretnjom udesno povećava se x vrijednost te kretnjom prema dolje povećava se y vrijednost. Funkcijom *pyautogui.size()* dohvaća se dimenzija zaslona.

Metodom *pyautogui.locateOnScreen()* danu sliku pronalazi na zaslonu tako da traži točan raspored piksela kao na slici. Pronalaskom ikonice moguće je odrediti x i y koordinate te simulirati lijevi klik miša na te koordinate metodom *pyautogui.click().* Na taj način ostvareno je otvaranje Google Chrome i Notepad aplikacija. Definicije funkcija prikazane su na slici 3.2.2. Veliki nedostatak ove funkcije je taj da ukoliko postoji razlika i u jednom pikselu prilikom uspoređivanja slike i tražene ikonice, funkcija neće vratiti očekivani izlaz.

```
def openNotepad():
    pyautogui.size()
    icon_location = pyautogui.locateOnScreen(r'screenshots/notepadLogo.png')
    if icon_location is not None:
            if len(icon_location) == 4:
                pyautogui.click(x=icon_location.left, y=icon_location.top, duration=0.25)
    else:
        print("Could not locate Notepad Icon on screen")

def openChrome():
    pyautogui.size()
    icon_location = pyautogui.locateOnScreen(r'screenshots/chromeLogo.png')
    if icon_location is not None:
            if len(icon_location) == 4:
                pyautogui.click(x=icon_location.left, y=icon_location.top, duration=0.25)
    else:
        print("Could not locate Chrome Icon on screen")
```

Slika 3.2.2. Definicije funkcija za otvaranje aplikacija

Simulacija pritiskanja tipki ostvarena je funkcijom *pyautogui.press()* kojoj se kao argument zadaje ime radnje koju tipka izvodi, dok se pomicanje srednje tipke miša ostvaruje funkcijom *pyautogui.scroll()* prilikom čega se kao argument predaje vrijednost za koju je potrebno pomaknuti miš u pikselima.

Slikom 3.2.3 danom u nastavku prikazan je dio koda kojim se provjerava koja je naredba rečena i izvođenje pripadajuće GUI operacije ovisno o vrijednosti koja je spremljena u *speech_to_text* varijabli.

Nadalje, mapiranje funkcija koje se izvode na određene glasovne naredbe prikazano je slikom 3.2.4.

```
39          if (speech_to_txt == "quit") or (speech_to_txt == "exit"):
40              break
41          elif speech_to_txt == "scroll up":
42              pyautogui.scroll(50)
43          elif speech_to_txt == "scroll down":
44              pyautogui.scroll(-50)
45          elif speech_to_txt == "volume up":
46              pyautogui.press('volumeup')
47          elif speech_to_txt == "volume down":
48              pyautogui.press('volumedown')
49          elif speech_to_txt == "mute" or speech_to_txt=="unmute":
50              pyautogui.press('volumemute')
51          elif speech_to_txt == "open chrome":
52              openChrome()
53          elif speech_to_txt == "open notepad":
54              openNotepad()
```

Slika 3.2.3. Izvođenje operacija ovisno o izrečenoj naredbi

Glasovna naredba	**Funkcija**
Scroll up	Pomicanje dokumenta prema gore
Scroll down	Pomicanje dokumenta prema dolje
Volume up	Povećanje razine zvuka
Volume down	Smanjenje razine zvuka
Mute/Unmute	Isključivanje/uključivanje zvuka
Open Chrome	Otvaranje Google Chrome preglednika
Open Notepad	Otvaranje Notepad uređivača teksta
Quit/Exit	Prekid izvođenja

Slika 3.2.4. Naredbe aplikacije

4. Testiranje aplikacije

Kao što je prethodno navedeno, SpeechRecognition biblioteka nudi više API-ja kojima se vrši obrada i transformacija glasa u tekst. Kako bi se utvrdilo koji najbolje odgovara danome problemu, izvršeno je testiranje aplikacije korištenjem sljedećih API-ja: CMU Sphinx, Google Speech Recognition, Google Cloud Speech API, Microsoft Bing Voice Recognition i IBM Speech to Text.

Prvo svojstvo koje je potrebno uvažiti je mogućnost korištenja API-ja s ili bez internetske povezanosti. Kako bi pristupili određenim *recognizer* objektima, potrebna je internet konekcija koja šalje serveru glasovni oblik, prilikom čega server obrađuje podatke, pretvara ih u tekst te ga vraća klijentu kao izlaz. Sljedećom tablicom prikazani su korišteni pristupi i je li potreban pristup internetu za njihov rad.

	CMU Sphinx	**Google Speech Recognition**	**Google Cloud Speech API**	**Microsoft Bing Voice Recognition**	**IBM Speech to Text**
Potreban internet	NE	DA	DA	DA	DA

Tablica 4.1. Potrebnost interneta za korištenje API-ja

Glavna značajka koja se testira je koliko dobro pojedini API klasificira govor i pretvara ga u tekst. Kako bi se dobili što precizniji rezultati, testiranje je izvršeno u 4 kruga. Svakim krugom prolazi se kroz sve naredbe i kroz sve API-je. Svaka naredba izrečena je 10 puta te se na temelju točnih i netočnih klasifikacija utvrđuje stopa pogreške. Također, svaki krug naredbe zadaje drugi govornik. U testiranju su sudjelovala 4 govornika različite dobi i spola, stariji i mlađi muškarac te starija i mlađa žena. Rezultati testiranja prikazani su u tablicom 4.2.

	CMU Sphinx	Google Speech Recognition	Google Cloud Speech API	Microsoft Bing Voice Recognition	IBM Speech to Text
Scroll up	7	2	1	3	2
Scroll down	6	3	3	4	2
Volume up	2	**0**	1	2	1
Volume down	3	0	0	2	0
Mute/unmute	2	1	0	1	0
Open Chrome	5	1	2	**0**	3
Open Notepad	4	1	0	2	1
Quit/Exit	1	0	0	0	2
Missclassified	30	8	7	14	11
WER (%)	37,5	10	**8,75**	17,5	13,75

Tablica 4.2. Rezultati testiranja

U tablici je prikazan broj pogrešno klasificiranih naredbi te u zadnjem retku postotak pogrešno klasificiranih naredbi (engl. Word error rate, WER). Kao što je vidljivo, najveći problem predstavljaju naredbe *Scroll up* i *Scroll down*, ponajviše iz razloga što se riječ *Scroll* često krivo klasificira kao *Call*. Riječi *Up* i *Down* u svim naredbama nisu predstavljala problem prilikom klasifikacije što je također vidljivo kod boljih rezultata *Volume up* i *Volume down* naredbi. *Open Chrome* i *Open Notepad* naredbe nisu predstavljale problem prilikom klasifikacije osim kod CMU Sphinx koji nije u potpunosti razumio izgovorenu naredbu. Najmanji broj krivo klasificiranih riječi vidljiv je kod naredbe *Quit*/*Exit*. Google Speech Recognition jedini je točno klasificirao sve primjere naredbe *Volume up,* dok je Microsoft Bing Voice Recognition jedini naredbu *Open Chrome* u potpunosti točno klasificirao svaki puta.

Bitno je napomenuti kako niti jedan API nije pokazao razliku između klasificiranja naredbi pojedinih govornika, što govori kako su sustavi kvalitetno izrađeni i jednako prepoznaju različite tonalitete glasova.

Iz tablice je također vidljivo kako je CMU Sphinx pokazao najlošije rezultate što se može interpretirati činjenicom da jedini radi bez potrebne internetske povezanosti. Ostala 4 API-ja ostvaruju slične rezultate, iako se za ovaj projektni zadatak najboljim pokazao Google Cloud Speech jer je postigao najmanju stopu pogreške.

5. Zaključak

Ovim projektom vidljivo je kako postoji više mogućnosti upravljanja Windows sustavom te je prikazana i korištena mogućnost izvođenja naredbi govorom. Testiranjem različitih API-ja s više govornika utvrđeno je kako nema razlike u klasificiranju naredbi ovisno o govorniku te da Google, IBM i Bing sustavi raspoznavanja govora pokazuju vrlo dobre i slične rezultate. CMU Sphinx pokazuje znatno lošije rezultate što je objašnjivo činjenicom da ne treba internet prilikom klasificiranja. Daljnim radom valjalo bi testirati veći skup API-ja kao i veći skup naredbi kako bi se utvrdili detaljniji i opširniji rezultati.

6. Literatura

https://pypi.org/project/SpeechRecognition/

https://pypi.org/project/PyAudio/

https://pypi.org/project/PyAutoGUI/

https://towardsdatascience.com/audio-deep-learning-made-simple-automatic-speech-recognition-asr-how-it-works-716cfce4c706

https://sonix.ai/history-of-speech-recognition

https://www.ibm.com/cloud/learn/speech-recognition

https://summalinguae.com/language-technology/guide-to-speech-recognition-technology/